

Lineamientos técnicos para trabajos de titulación Maestría en Big Data y Ciencia de Datos

1. Naturaleza del problema

El trabajo deberá abordar un problema real y pertinente cuya solución requiera el uso intensivo de datos y la aplicación de tecnologías de analítica avanzada, ingeniería de datos o inteligencia artificial.

No se considerarán válidos proyectos centrados únicamente en:

- Desarrollo CRUD tradicional.
- Implementación exclusiva de dashboards.
- Automatización administrativa sin procesamiento analítico.
- Integraciones tecnológicas sin explotación de datos.

2. Características mínimas de los datos (Criterio Big Data)

- Cumplir al menos 3 de las 8V del Big Data.
- Procesar ≥ 100.000 registros o integrar ≥ 3 fuentes o trabajar con tiempo real/datos distribuidos.
- Documentar origen, calidad y trazabilidad de datos.

3. Requerimientos técnicos mínimos

- Definir arquitectura de solución, arquitectura de datos, infraestructura, integración, seguridad, despliegue y monitoreo.
- Incluir como mínimo:

Ingesta → Procesamiento → Análisis → Consumo.

4. Herramientas, plataformas y tecnologías

- Justificar selección tecnológica.
- Ejemplos: Spark, Kafka, Airflow, Python, Fabric, PostgreSQL, Azure, AWS, APIs, etc.

5. Metodologías y estándares

- Aplicar al menos una metodología: CRISP-DM, TDSP, DataOps, MLOps, DAMA-DMBOK, ISO 25010 o ISO 27001.

6. Métricas e indicadores técnicos

- Definir indicadores cuantificables: Accuracy, Recall, F1, RMSE, Throughput, Latencia, tiempos de respuesta y KPIs de negocio.

7. Productos y entregables técnicos

- Documento técnico, código fuente, arquitectura, dataset, pipeline funcional, evidencia experimental y manual técnico.

8. Validación y demostración

- Demostrar funcionamiento, repetibilidad, comparación contra línea base y cumplimiento de objetivos.

9. Criterios diferenciadores de nivel maestría

- Integración tecnológica avanzada, escalabilidad, IA, automatización o impacto institucional.

10. Criterio de aceptación del tema

- Viabilidad técnica, disponibilidad de datos y generación de valor demostrable.

Se considera este lineamiento como herramienta para definir actividades, hitos, entregables y mecanismos de seguimiento acordes con las exigencias académicas y profesionales del programa.

A continuación, se detalla el Pipeline del proyecto de titulación Tabla1, y las especificaciones técnicas a considerar para el cumplimiento de los lineamientos antes mencionados (Tabla2)

Tabla1.- Rúbrica para Trabajo de Titulación – Maestría en Big Data

Dimensión	Criterio técnico	Aspectos a evaluar	Evidencia requerida
1	Problema de negocio y objetivos	El proyecto resuelve una necesidad real mediante datos	Caso de negocio, objetivos, KPIs
2	Arquitectura de solución	Diseño integral de captura, almacenamiento, procesamiento y visualización	Arquitectura lógica/física, diagramas
3	Integración e ingeniería de datos	Extracción, transformación, carga, integración y automatización	Pipeline ETL/ELT funcional
4	Calidad y preparación de datos	Limpieza, consistencia, enriquecimiento y gobierno básico	Dataset procesado y métricas de calidad
5	Desarrollo de analítica / IA	Construcción de modelos analíticos o reglas inteligentes	Código, notebooks, modelos
6	Validación funcional	La solución cumple el objetivo planteado	Casos de prueba, demostración
7	Rendimiento y escalabilidad	Tiempo de procesamiento y crecimiento del sistema	Pruebas de carga o benchmark
8	Implementación y despliegue	Solución ejecutable y operativa	Docker, nube, servidor o ambiente productivo
9	Seguridad y operación	Control de acceso, respaldo, monitoreo	Evidencia operativa
10	Valor generado	Beneficio medible del proyecto	KPIs antes/después

Condición mínima de aceptación

Para aprobar el tema:

- Cumplir los 10 requisitos obligatorios.
- Alcanzar complejidad técnica de nivel maestría.
- Demostrar viabilidad de implementación.
- Mostrar generación de valor basada en datos.
- Cumplir al menos 3 lineamientos técnicos

Tabla 2.- Lineamientos técnicos a cumplir para Trabajo de Titulación – Maestría en Big Data

Indicador / Característica	Descripción / Pregunta de validación	Nivel de exigencia típico en tesis de posgrado	¿Big Data clásico?	¿Big Data moderno (2025–2026)?
Volumen	¿Los datos superan consistentemente los cientos de GB / varios TB en crudo? ¿Se habla de escalas de billones de registros?	> 1–10 TB (tesis) / > 100 TB–PB (trabajos industriales)	Sí (fuerte)	Sí, pero ya no es suficiente solo
Velocidad	¿Se genera / ingiere / procesa datos en streaming o near-real-time? (≥ miles–millones de eventos/segundo)	≥ 10k–100k eventos/seg o latencia < 1–5 seg en producción	Sí (muy fuerte)	Muy importante
Variedad	¿Se combinan ≥ 3–4 tipos de datos muy heterogéneos? (ej. texto+imágenes+series temporales+JSON+logs+geospacial+video)	≥ 3 formatos muy distintos + al menos uno no estructurado	Sí (fuerte)	Casi obligatorio
Veracidad / Incertidumbre	¿Los datos tienen ruido significativo, missing values altos, sesgos, duplicados, fuentes no confiables? ¿Se requiere limpieza avanzada / data quality pipeline?	≥ 15–30% de ruido o múltiples fuentes con diferente confianza	Sí	Importante
Valor / Complejidad del insight (Value)	¿El aporte principal es descubrir patrones no obvios, predicciones a muy gran escala o insights que no se obtienen con bases de datos convencionales?	Insights novedosos que justifican el costo computacional	Sí (decisivo)	Decisivo
Infraestructura distribuida requerida	¿Es estrictamente necesario Hadoop, Spark, Flink, Kafka, Dask, Ray, Databricks, Snowflake, BigQuery, etc.? ¿No alcanza con PostgreSQL, pandas o R en una sola máquina?	Sí, imposible o muy ineficiente en máquina única	Sí (muy fuerte)	Muy fuerte

Escalabilidad horizontal demostrada	¿La solución escala lineal o casi lineal al aumentar nodos/datos? ¿Se midió speedup / weak scaling / strong scaling?	Experimentos con 4–10+ nodos o simulación realista	Sí	Esperado
Procesamiento en batch + streaming	¿Se combinan batch processing + streaming / micro-batching en la misma arquitectura?	Lambda / Kappa architecture o híbridos modernos	Sí	Fuerte
Uso intensivo de datos no estructurados	≥ 40–60% del valor proviene de texto (NLP a gran escala), imágenes, video, audio, grafos masivos, logs, sensores IoT	Sí, procesamiento avanzado (ej. embeddings, visión, GNN)	Sí	Casi obligatorio
Costo computacional significativo	¿El procesamiento requiere cientos–miles de core-horas? ¿Uso intensivo de GPU/TPU para pre-procesamiento o feature engineering?	> 500–1000 core-horas en cluster	Sí	Sí
Técnicas propias de Big Data	¿Se implementan o mejoran algoritmos escalables? (ej. Spark MLlib, distributed GNN, approximate algorithms, sketch algorithms, sampling avanzado)	Más allá de scikit-learn básico	Sí	Muy fuerte
Fenómeno social / IoT / web-scale	¿Los datos provienen de redes sociales masivas, sensores IoT a gran escala, logs de plataformas web, transacciones financieras masivas, genómica a escala poblacional?	Sí (Twitter/X, TikTok, sensores ciudad inteligente, etc.)	Sí	Fuerte