



UNIVERSIDAD TECNOLÓGICA ISRAEL
ESCUELA DE POSGRADOS “ESPOG”

MAESTRÍA EN BIG DATA Y DATA SCIENCE

PLAN PARA EL TRABAJO DE TITULACIÓN

Tema:
Integración de analítica en tiempo real y LLMs en la ingesta de metadatos y grabaciones telefónicas, para identificar prácticas de atención críticas y predecir anomalías en el rendimiento de los agentes de callcenter.
Autores/as:
MIÑO FLORES CARLOS ENRIQUE

Quito – Ecuador
2026

I. REVISIÓN DE LITERATURA

La operación de los centros de contacto o call centers de venta genera de forma continua dos clases de datos heterogéneos: metadatos estructurados de cada llamada, es decir, los registros de detalle de llamada (CDR) y grabaciones de voz no estructuradas que concentran la mayor parte del valor informativo. La auditoría tradicional de estas interacciones es manual, lo que limita su cobertura y su capacidad de producir métricas oportunas para la toma de decisiones gerenciales. Por su volumen, velocidad y variedad, estos datos exhiben características propias del paradigma Big Data, y su tratamiento se complica porque las grabaciones contienen información personal y financiera, lo que impone restricciones de privacidad y cumplimiento normativo, como la anonimización de datos sensibles, que condicionan el diseño de cualquier solución analítica. La convergencia reciente de la analítica en tiempo real, el reconocimiento automático del habla (ASR) y los modelos de lenguaje de gran escala (LLM) abre una vía para automatizar el análisis de la calidad de la gestión, identificar prácticas de atención críticas y anticipar anomalías en el desempeño de los agentes. Esta revisión organiza el estado del arte en cuatro ejes temáticos: arquitecturas de analítica en tiempo real, ASR y analítica de voz, LLM y procesamiento de lenguaje natural (PLN) para el análisis de conversaciones, y detección de anomalías y predicción del rendimiento.

A. Analítica en tiempo real y arquitecturas de datos masivos

El procesamiento de grandes volúmenes de datos con requisitos de latencia ha cristalizado en dos patrones arquitectónicos de referencia. La arquitectura Lambda combina una capa de procesamiento por lotes con una capa de velocidad, lo que permite reconciliar la exactitud del histórico con la baja latencia del flujo entrante [1]. No obstante, la duplicación de lógica entre ambas capas motivó la arquitectura Kappa, que unifica el procesamiento en un único flujo de eventos y simplifica el mantenimiento [2]. Estos fundamentos siguen vigentes en propuestas contemporáneas: Khattach et al. describen una arquitectura de extremo a extremo que integra ingesta por streaming y tuberías de aprendizaje automático para analítica en tiempo real y mantenimiento predictivo sobre datos del Internet de las cosas [3], evidenciando la madurez de combinar plataformas de mensajería de eventos para la ingesta con motores de cómputo distribuido para el procesamiento por lotes. En el plano gerencial, Pincay y Marcillo muestran que la integración de Big Data y aprendizaje automático mejora la automatización de las decisiones empresariales [4]. Para el problema abordado, estas arquitecturas justifican un diseño híbrido que procese cada llamada casi en tiempo real al finalizar y que, en paralelo, permita el reprocesamiento masivo del histórico por rangos de fechas con la misma lógica de limpieza y validación.

B. Reconocimiento automático del habla y analítica de voz

El análisis de grabaciones telefónicas depende de transcribir la voz a texto y de atribuir cada intervención a su interlocutor. En grabaciones monocanal mezcladas, donde asesor y cliente comparten un único canal, la diarización resulta indispensable; Wang et al. proponen DiarizationLM, un marco que emplea un LLM para post-procesar y corregir la salida de los sistemas de diarización, reduciendo los errores de atribución de hablante [5]. La calidad de la transcripción, sin embargo, está sujeta a riesgos documentados: Koenecke et al. evidencian que modelos de ASR como Whisper pueden producir "alucinaciones", es decir texto inexistente en el audio, con consecuencias dañinas en contextos sensibles [6], lo que obliga a incorporar mecanismos de verificación de las salidas. Asimismo, Harris et al. cuantifican sesgos de género y dialecto en el ASR [7], un hallazgo especialmente pertinente para el español ecuatoriano, cuyas variantes pueden degradar la precisión del reconocimiento. Más allá del contenido léxico, la dimensión

paralingüística aporta valor analítico: Barhoumi y BenAyed presentan un sistema de reconocimiento de emociones en el habla en tiempo real basado en aprendizaje profundo y aumento de datos [8], capacidad clave para evaluar el trato y la evolución del sentimiento tanto del cliente como del asesor a lo largo de la conversación.

C. LLM y PLN para análisis de conversaciones, sentimiento y cumplimiento

Los LLM han ampliado de forma notable el alcance del PLN. Las revisiones de Minaee et al. [9] y de Raiaan et al. [10] sistematizan sus arquitecturas, capacidades emergentes y limitaciones, y ofrecen el marco conceptual para su adopción analítica. En la tarea específica de análisis de sentimiento, Zhang et al. realizan una evaluación crítica del desempeño de los LLM y advierten que, pese a su versatilidad en escenarios sin ajuste fino, persisten brechas frente a modelos especializados, sobre todo en el análisis de sentimiento basado en aspectos [11]. Estas capacidades habilitan la evaluación automatizada de la calidad de venta, adherencia al guion, detección de frases engañosas y verificación del cumplimiento normativo directamente sobre las transcripciones. Dado que el caso de estudio combina metadatos, audio y texto, resulta pertinente la revisión de Quintero Bernal et al. sobre fusión de datos multimodal y sus condiciones adversas [12], que orienta la integración coherente de fuentes heterogéneas para enriquecer el análisis semántico.

D. Detección de anomalías y predicción del rendimiento

Anticipar caídas de desempeño y comportamientos atípicos de los agentes requiere técnicas de detección de anomalías y de pronóstico. Su et al., en una revisión sistemática, examinan el uso de LLM para el pronóstico y la detección de anomalías, mostrando su aplicación creciente en conjunto con métodos clásicos [13]. En el dominio afín de las telecomunicaciones, Edozie et al. revisan los avances de la inteligencia artificial para la detección de anomalías en redes [14]. Cuando se carece de etiquetas abundantes, situación habitual cuando las auditorías manuales son escasas, las técnicas no supervisadas resultan idóneas: Berahmand et al. compendian los autocodificadores y sus aplicaciones para la reducción de dimensionalidad y la detección de anomalías [15], mientras que Kong et al. revisan el aprendizaje profundo para el pronóstico de series temporales [16], aplicable a indicadores operativos como la contactabilidad, la tasa de conversión y la duración media por agente.

Síntesis y vacío de investigación

En conjunto, la literatura demuestra la madurez individual de cada bloque, arquitecturas de streaming, ASR con diarización, LLM para sentimiento y cumplimiento, y detección de anomalías, pero su integración en un pipeline de extremo a extremo continúa siendo escasa. No se identifican propuestas que articulen, en un único flujo casi en tiempo real, la ingesta de metadatos y grabaciones, la transcripción y anonimización de datos sensibles, el análisis del cumplimiento normativo mediante LLM y la predicción de anomalías en el rendimiento de los agentes, particularmente en español y en contextos de venta regulada por entidades financieras. La mayoría de los trabajos validan sus aportes sobre bloques aislados y rara vez incorporan, de forma conjunta, la privacidad por diseño y la trazabilidad exigida cuando se procesan datos personales y financieros. Atender esta brecha permitiría sustituir la auditoría manual y de baja cobertura por un sistema reproducible que genere métricas de calidad y alertas de riesgo de forma sistemática. Este vacío fundamenta el problema de investigación del presente trabajo.

II. PROBLEMA DE INVESTIGACIÓN

Los centros de contacto de venta saliente generan volúmenes crecientes de datos, en su mayoría grabaciones de voz no estructuradas que rara vez se procesan en su totalidad; en el caso de estudio se acumulan más de 100 GB de audio y más de 100.000 registros de detalle de llamada (CDR) desde 2017. La evaluación del desempeño en infraestructuras PBX como Asterisk se realiza mediante auditorías manuales que cubren una fracción mínima de las interacciones, lo que introduce una alta latencia operativa e impide detectar a tiempo anomalías, malas prácticas de atención y riesgos de incumplimiento normativo ante las entidades financieras.

Aunque los CDR se almacenan en bases relacionales con analítica descriptiva, las herramientas tradicionales no procesan el contenido semántico del audio y desaprovechan la mayor parte de la información. Los LLM han demostrado eficacia en el análisis de sentimiento y la extracción de entidades [11], y existen arquitecturas maduras de analítica en tiempo real [3]; sin embargo, persiste un vacío: la ausencia de arquitecturas de referencia que integren de forma nativa los LLM con la analítica de streaming para procesar concurrentemente metadatos relacionales y flujos de voz a escala, incluyendo la predicción de anomalías [13].

A partir de este vacío se formula la siguiente pregunta de investigación:

¿Cómo diseñar e implementar una arquitectura que integre Modelos de Lenguaje de Gran Escala (LLM) y analítica en tiempo real sobre registros CDR y grabaciones de audio para identificar de forma escalable prácticas de atención críticas y predecir anomalías en el rendimiento de los agentes de un call center?

Hipótesis: una arquitectura modular que combine analítica de streaming y LLM sobre metadatos CDR y transcripciones de audio permitirá analizar las interacciones a escala con una precisión estadísticamente superior en los KPIs de calidad y reducir el tiempo de detección de anomalías frente a la auditoría manual.

III. OBJETIVO GENERAL

- Implementar una arquitectura modular de Big Data para el procesamiento concurrente de metadatos CDR y grabaciones de audio no estructuradas, mediante la integración de analítica en tiempo real (streaming) y Modelos de Lenguaje de Gran Escala (LLM), con el fin de identificar prácticas de atención críticas y predecir anomalías en el rendimiento de los agentes de un call center.

IV. OBJETIVOS ESPECÍFICOS

- Contextualizar los fundamentos teóricos sobre analítica en tiempo real, reconocimiento automático del habla (ASR) y Modelos de Lenguaje de Gran Escala aplicados al análisis de interacciones de call center, mediante una revisión sistemática de la literatura científica actualizada.
- Diagnosticar el proceso actual de auditoría y la calidad, trazabilidad y requerimientos de los datos, registros CDR y grabaciones, mediante el análisis de un conjunto representativo de llamadas y de la infraestructura existente (Asterisk/MySQL).
- Desarrollar una arquitectura modular que integre ingesta por streaming, procesamiento distribuido por lotes, transcripción con anonimización de datos sensibles y análisis mediante LLM, para identificar prácticas de atención críticas y construir indicadores de calidad y de rendimiento de los agentes.

- Validar el impacto de la arquitectura propuesta en un entorno real de la empresa, comparando indicadores antes y después de su implementación, cobertura de auditoría, precisión en la identificación de prácticas críticas y tiempo de detección de anomalías, frente a la auditoría manual como línea base.

V. JUSTIFICACIÓN PRÁCTICA

La presente investigación propone una arquitectura modular de Big Data que integra analítica en tiempo real y Modelos de Lenguaje de Gran Escala para procesar de forma concurrente los metadatos CDR y las grabaciones de las llamadas, incorporando transcripción automática, anonimización de datos sensibles y evaluación automatizada de la calidad de la gestión. La solución sustituye la auditoría manual, que hoy cubre una fracción mínima de las interacciones, por un análisis sistemático y casi en tiempo real de la totalidad de las llamadas.

En el plano técnico, aporta una integración eficiente entre el procesamiento por streaming y por lotes con privacidad por diseño, viable sobre la infraestructura existente (Asterisk y base de datos relacional). En el plano científico, contribuye con una arquitectura de referencia replicable que articula streaming, reconocimiento automático del habla y LLM para la identificación de prácticas críticas y la predicción de anomalías, atendiendo un vacío señalado en la literatura. En el plano social, fortalece la protección del consumidor al detectar prácticas de venta engañosas y reducir el riesgo de sanciones y reclamos ante las entidades financieras; a la vez, ofrece a la empresa métricas objetivas para mejorar la gestión, la conversión y la retroalimentación a los agentes, optimizando la toma de decisiones gerenciales.

VI. VINCULACIÓN CON LA SOCIEDAD Y BENEFICIARIOS DIRECTOS

El principal aporte de vinculación es la capacitación y asesoría a la empresa donde la solución se implementará. Se transferirá conocimiento al equipo gerencial, al área de auditoría y calidad, y a los supervisores, mediante asesoría en el uso del tablero analítico, la interpretación de los indicadores de calidad y rendimiento, y la respuesta a las alertas de prácticas críticas y anomalías. Este aporte se articula directamente con la validación por implementación real planteada en los objetivos específicos, ya que serán los propios usuarios de la gerencia quienes consuman y operen la solución.

Como contribución a la sociedad, el proyecto promueve ventas más transparentes y la protección del consumidor, al detectar prácticas engañosas y favorecer el cumplimiento normativo ante las entidades financieras y los organismos de control; además, brinda a los agentes una retroalimentación objetiva que mejora sus condiciones laborales.

Entre los productos tecnológicos se entregará el dashboard operativo, la arquitectura del pipeline y su documentación técnica, junto con material de capacitación (manuales y guías de uso). Los beneficiarios directos son la gerencia, el equipo de auditoría y calidad, los supervisores y los agentes del call center; de forma indirecta, los clientes. El proyecto aporta a los ODS 8 y 9.

VII. MÉTODO DE INVESTIGACIÓN

Describir en detalle los elementos del método de investigación:

A. Enfoque de la Investigación

Indicar si el enfoque es cuantitativo, cualitativo o mixto, y especificar el método correspondiente (p. ej., experimental, descriptivo, estudio de caso, etc.).

B. Procedimiento

Describir las etapas y actividades del proceso de investigación de forma secuencial.

C. Participantes

Caracterizar la población y muestra. Incluir criterios de inclusión y exclusión cuando aplique.

D. Instrumentos

Detallar los instrumentos de recolección de datos utilizados (encuestas, entrevistas, sensores, software, etc.) y justificar su selección.

E. Análisis de Datos

Describir las técnicas estadísticas o analíticas empleadas para procesar e interpretar los datos obtenidos.

VIII. REFERENCIAS

- [1] M. Kiran, P. Murphy, I. Monga, J. Dugan, y S. S. Baveja, “Lambda architecture for cost-effective batch and speed big data processing”, en *2015 IEEE International Conference on Big Data (Big Data)*, 2015. doi: 10.1109/bigdata.2015.7364082.
- [2] J. Kreps, “Questioning the Lambda Architecture”, 2014. [En línea]. Disponible en: <https://www.oreilly.com/radar/questioning-the-lambda-architecture/>
- [3] O. Khattach, O. Moussaoui, y M. Hassine, “End-to-End Architecture for Real-Time IoT Analytics and Predictive Maintenance Using Stream Processing and ML Pipelines”, *Sensors*, vol. 25, núm. 9, p. 2945, 2025, doi: 10.3390/s25092945.
- [4] Y. A. Pincay Mendoza, V. C. Marcillo Salazar, V. V. García Constante, A. G. Espinoza Cesme, A. M. Morán Holguín, y G. A. Veloz Santa Cruz, “Decisiones gerenciales automatizadas: integrando Big Data y Machine Learning”, *Cienc. Desarro.*, vol. 28, núm. 1, p. 357, 2025, doi: 10.21503/cyd.v28i1.2830.
- [5] Q. Wang, Y. Huang, G. Zhao, E. Clark, W. Xia, y H. Liao, “DiarizationLM: Speaker Diarization Post-Processing with Large Language Models”, en *Interspeech 2024*, 2024. doi: 10.21437/interspeech.2024-209.
- [6] A. Koenecke, A. S. G. Choi, K. X. Mei, H. Schellmann, y M. Sloane, “Careless Whisper: Speech-to-Text Hallucination Harms”, en *The 2024 ACM Conference on Fairness, Accountability, and Transparency*, 2024. doi: 10.1145/3630106.3658996.
- [7] C. Harris, C. Mgbahurike, N. Kumar, y D. Yang, “Modeling Gender and Dialect Bias in Automatic Speech Recognition”, en *Findings of the Association for Computational Linguistics: EMNLP 2024*, 2024. doi: 10.18653/v1/2024.findings-emnlp.890.
- [8] C. Barhoumi y Y. BenAyed, “Real-time speech emotion recognition using deep learning and data augmentation”, *Artif. Intell. Rev.*, vol. 58, núm. 2, 2024, doi: 10.1007/s10462-024-11065-x.
- [9] S. Minaee *et al.*, “Large Language Models: A Survey”, 2024. doi: 10.48550/arxiv.2402.06196.
- [10] M. A. K. Raiaan *et al.*, “A Review on Large Language Models: Architectures, Applications, Taxonomies, Open Issues and Challenges”, *IEEE Access*, vol. 12, pp. 26839–26874, 2024, doi: 10.1109/access.2024.3365742.
- [11] W. Zhang, Y. Deng, B. Liu, S. Pan, y L. Bing, “Sentiment Analysis in the Era of Large Language Models: A Reality Check”, en *Findings of the Association for Computational Linguistics: NAACL 2024*, 2024. doi: 10.18653/v1/2024.findings-naacl.246.
- [12] D. F. Quintero Bernal, H. Kaschel, y J. Kern, “Una revisión de fusión de datos multimodal: aplicaciones y condiciones adversas”, *Inge CuC*, vol. 21, núm. 1, pp. 95–114, 2025, doi: 10.17981/ingecuc.21.1.2025.08.

- [13] J. Su *et al.*, “Large Language Models for Forecasting and Anomaly Detection: A Systematic Literature Review”, 2024. doi: 10.48550/arxiv.2402.10350.
- [14] E. Edozie, A. N. Shuaibu, B. O. Sadiq, y U. K. John, “Artificial intelligence advances in anomaly detection for telecom networks”, *Artif. Intell. Rev.*, vol. 58, núm. 4, 2025, doi: 10.1007/s10462-025-11108-x.
- [15] K. Berahmand, F. Daneshfar, E. S. Salehi, Y. Li, y Y. Xu, “Autoencoders and their applications in machine learning: a survey”, *Artif. Intell. Rev.*, vol. 57, núm. 2, 2024, doi: 10.1007/s10462-023-10662-6.
- [16] X. Kong *et al.*, “Deep learning for time series forecasting: a survey”, *International Journal of Machine Learning and Cybernetics*, vol. 16, núm. 7–8, pp. 5079–5112, 2025, doi: 10.1007/s13042-025-02560-w.

IX. INFORMACIÓN ADMINISTRATIVA

Tipo de trabajo de titulación:	☐ Proyecto ☐ Artículo científico
Aprobado por:	

Nota: Este plan debe presentarse en el estilo académico que corresponde a la maestría. Para maestrías con énfasis en ingeniería y tecnología, se emplea el estilo IEEE. Las referencias se numeran en orden de aparición entre corchetes, p. ej., [1], [2], ...